

Lenguajes de marcas y Sistemas de gestión de la información

HTML: La codificación de caracteres (CHARSET)

¿Qué es la codificación de caracteres?

La **codificación de caracteres** es el método que permite convertir un carácter de un lenguaje natural en un símbolo de otro sistema de representación, como un número o una secuencia de pulsos de un sistema eléctrico.

Se basa en definir tablas que relacionen el carácter en lenguaje natural con su correspondencia en el lenguaje del ordenador.

Dichas tablas se denominan **conjunto de caracteres** o **charset**.

Un ejemplo de conjuntos de caracteres universales son el código morse y el braille.

En el mundo de la tecnología, los charset más utilizados son ASCII, ISO-8859 o ASCII Extendido, y UNICODE.

ASCII

El conjunto de caracteres **ASCII** fue publicado en 1967 por **ANSI** o **American National Standard Code for Information Exchange**.

Utiliza 7 bits para representar los caracteres y deja el ultimo bit para la paridad o control de errores, por lo que solo es capaz de representar 128 caracteres (mayúsculas, minúsculas, números, símbolos de puntuación y algunos caracteres de control).

No incluye los caracteres acentuados, la apertura de la interrogación, ni otros símbolos necesarios para el castellano por ejemplo.

TABLA ASCII

Caracteres de control ASCII			
DEC	HEX	Símbolo ASCII	
00	00h	NULL	(carácter nulo)
01	01h	SOH	(inicio encabezado)
02	02h	STX	(inicio texto)
03	03h	ETX	(fin de texto)
04	04h	EOT	(fin transmisión)
05	05h	ENQ	(enquiry)
06	06h	ACK	(acknowledgement)
07	07h	BEL	(timbre)
08	08h	BS	(retroceso)
09	09h	HT	(tab horizontal)
10	0Ah	LF	(salto de línea)
11	0Bh	VT	(tab vertical)
12	0Ch	FF	(form feed)
13	0Dh	CR	(retorno de carro)
14	0Eh	SO	(shift Out)
15	0Fh	SI	(shift In)
16	10h	DLE	(data link escape)
17	11h	DC1	(device control 1)
18	12h	DC2	(device control 2)
19	13h	DC3	(device control 3)
20	14h	DC4	(device control 4)
21	15h	NAK	(negative acknowle.)
22	16h	SYN	(synchronous idle)
23	17h	ETB	(end of trans. block)
24	18h	CAN	(cancel)
25	19h	EM	(end of medium)
26	1Ah	SUB	(substitute)
27	1Bh	ESC	(escape)
28	1Ch	FS	(file separator)
29	1Dh	GS	(group separator)
30	1Eh	RS	(record separator)
31	1Fh	US	(unit separator)
127	20h	DEL	(delete)

Caracteres ASCII imprimibles								
DEC	HEX	Símbolo	DEC	HEX	Símbolo	DEC	HEX	Símbolo
32	20h	espacio	64	40h	@	96	60h	`
33	21h	!	65	41h	A	97	61h	a
34	22h	"	66	42h	B	98	62h	b
35	23h	#	67	43h	C	99	63h	c
36	24h	\$	68	44h	D	100	64h	d
37	25h	%	69	45h	E	101	65h	e
38	26h	&	70	46h	F	102	66h	f
39	27h	'	71	47h	G	103	67h	g
40	28h	(72	48h	H	104	68h	h
41	29h)	73	49h	I	105	69h	i
42	2Ah	*	74	4Ah	J	106	6Ah	j
43	2Bh	+	75	4Bh	K	107	6Bh	k
44	2Ch	,	76	4Ch	L	108	6Ch	l
45	2Dh	-	77	4Dh	M	109	6Dh	m
46	2Eh	.	78	4Eh	N	110	6Eh	n
47	2Fh	/	79	4Fh	O	111	6Fh	o
48	30h	0	80	50h	P	112	70h	p
49	31h	1	81	51h	Q	113	71h	q
50	32h	2	82	52h	R	114	72h	r
51	33h	3	83	53h	S	115	73h	s
52	34h	4	84	54h	T	116	74h	t
53	35h	5	85	55h	U	117	75h	u
54	36h	6	86	56h	V	118	76h	v
55	37h	7	87	57h	W	119	77h	w
56	38h	8	88	58h	X	120	78h	x
57	39h	9	89	59h	Y	121	79h	y
58	3Ah	:	90	5Ah	Z	122	7Ah	z
59	3Bh	;	91	5Bh	[123	7Bh	{
60	3Ch	<	92	5Ch	\	124	7Ch	
61	3Dh	=	93	5Dh]	125	7Dh	}
62	3Eh	>	94	5Eh	^	126	7Eh	~
63	3Fh	?	95	5Fh	_			

ASCII EXTENDIDO o ISO-8859

El **ISO-8859** utiliza 8 bits para representar los caracteres, por lo que es capaz de representar hasta 256, que es suficiente para representar todos los caracteres de un lenguaje concreto.

Los 128 primeros caracteres coinciden con los ASCII de la tabla original y los 128 siguientes contienen los caracteres extra añadidos.

Su tamaño sigue siendo insuficiente para representar todos los caracteres de todos los alfabetos conocidos, por lo que cada región tiene su propia especialización.

ASCII EXTENDIDO o ISO-8859

ISO 8859-1: Latin-1 Europa occidental.

ISO 8859-2: Latin-2 Europa occidental y Centroeuropa.

ISO 8859-3: Latin-3 Europa occidental y Europa del sur.

ISO 8859-4: Latin-4 Europa occidental y Países Bálticos (lituano, estonio y lapón).

ISO 8859-5: Alfabeto cirílico.

ISO 8859-6: Árabe.

ISO 8859-7: Griego.

ISO 8859-8: Hebreo.

ASCII EXTENDIDO o ISO-8859

ISO 8859-9: Latin-5 Europa occidental y turco.

ISO 8859-10: Latin-6 Europa occidental con nórdico, lapón y esquimal.

ISO 8859-11: Tailandés.

ISO 8859-13: Latin-7 Idiomas bálticos y polaco.

ISO 8859-14: Latin-8 Idiomas celtas (gaélico, irlandés, escocés, welsh).

ISO 8859-15: Latin-9 Añade el símbolo de Euro y otros a ISO 8859-1.

ISO 8859-16: Idiomas centroeuropeos (polaco, checo, eslovaco, húngaro, albaniano, rumano, alemán e italiano).

TABLA ASCII EXTENDIDA

ASCII extendido											
DEC	HEX	Simbolo	DEC	HEX	Simbolo	DEC	HEX	Simbolo	DEC	HEX	Simbolo
128	80h	Ç	160	A0h	á	192	C0h	Ł	224	E0h	Ó
129	81h	ü	161	A1h	í	193	C1h	ł	225	E1h	ô
130	82h	é	162	A2h	ó	194	C2h	ŧ	226	E2h	Ô
131	83h	â	163	A3h	ú	195	C3h	Ƨ	227	E3h	Ò
132	84h	ä	164	A4h	ñ	196	C4h	—	228	E4h	õ
133	85h	à	165	A5h	Ñ	197	C5h	÷	229	E5h	Õ
134	86h	á	166	A6h	ª	198	C6h	ä	230	E6h	μ
135	87h	ç	167	A7h	º	199	C7h	Ä	231	E7h	þ
136	88h	ê	168	A8h	¿	200	C8h	Ĺ	232	E8h	ƒ
137	89h	ë	169	A9h	®	201	C9h	Œ	233	E9h	ù
138	8Ah	è	170	AAh	¬	202	CAh	ƒ	234	EAh	Ú
139	8Bh	ï	171	ABh	½	203	CBh	ƒ	235	EBh	Û
140	8Ch	î	172	ACH	¼	204	CCh	ƒ	236	ECh	Ý
141	8Dh	ì	173	ADh	¡	205	CDh	=	237	EDh	Ÿ
142	8Eh	Ä	174	AEd	«	206	CEh	ƒ	238	EEh	—
143	8Fh	Å	175	AFh	»	207	CFh	□	239	EFh	·
144	90h	É	176	B0h	⋮	208	D0h	ø	240	F0h	
145	91h	æ	177	B1h	⋮	209	D1h	Ð	241	F1h	±
146	92h	Æ	178	B2h	⋮	210	D2h	È	242	F2h	—
147	93h	ô	179	B3h	⋮	211	D3h	Ê	243	F3h	¾
148	94h	ò	180	B4h	⋮	212	D4h	È	244	F4h	¶
149	95h	ò	181	B5h	À	213	D5h	Í	245	F5h	§
150	96h	û	182	B6h	Â	214	D6h	Î	246	F6h	÷
151	97h	ù	183	B7h	Ã	215	D7h	Ï	247	F7h	¿
152	98h	ÿ	184	B8h	©	216	D8h	Ĳ	248	F8h	°
153	99h	Ö	185	B9h	ƒ	217	D9h	ƒ	249	F9h	…
154	9Ah	Ü	186	BAh	ƒ	218	DAh	ƒ	250	FAh	·
155	9Bh	ø	187	BBh	ƒ	219	DBh	■	251	FBh	¹
156	9Ch	£	188	BCh	ƒ	220	DCh	■	252	FCh	º
157	9Dh	Ø	189	BDh	¢	221	DDh	■	253	FDh	²
158	9Eh	×	190	BEh	¥	222	DEh	■	254	FEh	■
159	9Fh	f	191	BFh	¬	223	DFh	■	255	FFh	

UNICODE

La norma **UNICODE** se desarrollo en 1991 como solución para recoger todos los caracteres de todos los alfabetos en una única tabla.

Representa en una única tabla más de cincuenta mil símbolos, que abarcan todos los alfabetos europeos, ideogramas chinos, japoneses, coreanos, lenguas muertas y mas de un millar de símbolos especiales.

Especifica un nombre y un identificador numérico entero único para cada carácter.

Cada ordenador utilizará, según su arquitectura, bloques de 8, 16 o 32 bits para representar dichos números enteros, por lo que se definen tres formas de codificación:

UTF-8 (Orientada a Byte con símbolos de longitud variable), **UTF-16** (Codificación de 16 bits de longitud variable) y **UTF-32** (Codificación de 32 bits de longitud fija).